



Détection des anomalies dans les analyses sanguines à l'aide du Machine Learning

Étudiants : El Mahdi Majdi & Kawtar Moukhaliss

Encadrant : Pr. Ismail Bettoui

Projet de Data Mining – Master BIAM (S2)

Introduction

L'objectif de ce projet est de détecter automatiquement les anomalies dans les analyses sanguines (CBC) à l'aide de méthodes de Machine Learning supervisé.

Le jeu de données utilisé provient de Zenodo et contient **523 844 analyses sanguines réelles**. Comme il ne comporte pas de variable cible, un système de labellisation a été construit à partir d'un score clinique pondéré basé sur des seuils physiologiques. Les observations dont le score est supérieur ou égal à 9 sont considérées comme des anomalies.

Méthodologie

Le pipeline comprend le nettoyage des données, la suppression des variables administratives, la conservation des valeurs aberrantes biologiquement plausibles, la création de la variable cible, la séparation stratifiée des données (80% apprentissage / 20% test), la normalisation avec **StandardScaler** (uniquement sur les données d'entraînement) ainsi que l'optimisation des modèles par validation croisée (**GridSearchCV**).

Cinq algorithmes supervisés ont été comparés :

- Régression Logistique
- K-Nearest Neighbors (KNN)
- Arbre de Décision
- Random Forest
- Support Vector Machine (SVM)

Deux configurations expérimentales ont été évaluées :

- **Expérience A** : utilisation des 9 variables du CBC (sanity check).
- **Expérience B1** : exclusion des variables principales (ERY, LEUKO, HB et PLT) afin de réduire le data leakage et d'évaluer un scénario plus réaliste.

Résultats

Les performances quasi parfaites observées lors de l'Expérience A résultent principalement du *data leakage*, puisque les variables utilisées pour construire le label sont également utilisées comme variables d'entrée. Les résultats de l'Expérience B1 sont donc retenus comme les plus représentatifs de la capacité réelle de généralisation des modèles.

Choix du meilleur modèle

L'**Arbre de Décision** est retenu comme meilleur modèle dans le scénario réaliste (Expérience B1) pour les raisons suivantes :

- le meilleur compromis entre Recall (0.7933) et F1-score (0.7346), critères prioritaires pour limiter les faux négatifs en contexte médical ;
- une excellente interprétabilité grâce à des règles de décision simples et facilement compréhensibles par les cliniciens ;
- un coût de calcul réduit, avec un temps d'inférence d'environ **21,8 s**, contre **43,4 s** pour le KNN et plus de **280 s** pour le SVM, facilitant son déploiement sur de grands volumes de données.

	Algorithme	Expérience	Type	Accuracy	Precision	Recall	F1-score
0	Decision Tree	A	Optimisé	0.999227	0.999199	0.998099	0.998649
1	Random Forest	A	Optimisé	0.998836	0.998864	0.997065	0.997964
2	SVM	A	Optimisé	0.943953	0.915469	0.885976	0.900481
3	KNN	A	Optimisé	0.938837	0.945269	0.834617	0.886504
4	Logistic Regression	A	Optimisé	0.835906	0.667759	0.849125	0.747600

	Algorithme	Expérience	Type	Accuracy	Precision	Recall	F1-score
0	Decision Tree	B1	Optimisé	0.835972	0.684035	0.793330	0.734640
1	Logistic Regression	B1	Optimisé	0.823650	0.649495	0.833784	0.730191
2	Random Forest	B1	Optimisé	0.847426	0.759586	0.683108	0.719320
3	SVM	B1	Optimisé	0.845594	0.761952	0.669735	0.712873
4	KNN	B1	Optimisé	0.841451	0.741077	0.685543	0.712229

FIGURE 1 – Comparaison des performances des cinq modèles sur les expériences A et B1.

Bien que le Random Forest affiche une accuracy (0.8474) et une AUC (0.936) légèrement supérieures à celles de l'Arbre de Décision, ce dernier est préféré en raison de son Recall nettement plus élevé (0.7933 contre 0.6831). Dans un contexte de diagnostic clinique, minimiser les faux négatifs est prioritaire par rapport à l'accuracy globale : un patient réellement anormal non détecté représente un risque plus grave qu'une fausse alerte. Le Random Forest, bien que plus robuste au surapprentissage grâce à l'agrégation de plusieurs arbres, se montre ici plus conservateur et manque davantage de cas anormaux. L'Arbre de Décision offre ainsi un meilleur compromis entre sensibilité clinique et interprétabilité, cette dernière étant elle-même renforcée par la simplicité d'un modèle unique par rapport à un ensemble de 100 arbres.

Limites

Malgré les résultats obtenus, cette étude présente certaines limites. Les labels ont été générés à partir de règles médicales plutôt que de diagnostics cliniques confirmés. Par ailleurs, bien que les variables principales (ERY, LEUKO, HB et PLT) aient été retirées dans l'Expérience B1, les variables secondaires (HK, MCV, MCHC, MCH et RDW) participent encore au calcul du score pondéré avec un poids plus faible. Un léger *data leakage* résiduel subsiste donc. Enfin, les modèles KNN et SVM ont été entraînés sur un sous-échantillon de 25 000 observations afin de limiter le temps de calcul.

Conclusion

Ce travail montre qu'un jeu de données clinique initialement non supervisé peut être transformé en problème de classification supervisée grâce à une stratégie de labellisation fondée sur des connaissances médicales. Parmi les cinq modèles évalués, l'Arbre de Décision offre le meilleur compromis entre performances, interprétabilité et coût computationnel, ce qui en fait une solution pertinente pour la détection automatique d'anomalies dans les analyses sanguines.

Disponibilité du code

L'ensemble du code source développé dans le cadre de ce projet est disponible sur GitHub :

<https://github.com/EL-MAHDI-MAJDI/cbc-anomaly-detection>